Федеральное государственное автономное образовательное учреждение высшего образования

«Московский физико-технический институт (государственный университет)»

Физтех-школа прикладной математики и информатики

Центр обучения проектированию и разработке игр

Направление подготовки: 09.04.01 Информатика и вычислительная техника **Направленность (профиль) подготовки**: Анализ данных и разработка информационных систем

Оптимизация потребления видеопамяти при помощи вычислительного графа в приложениях реального времени

(магистерская диссертация)

Студент:				
Санду Роман Александрович				
(подпись студента)				
Научный руководитель:				
Щербаков Александр Станиславович				
(подпись научного руководителя)				

Аннотация

Данная работа посвящена одному из подходов к построению архитектуры приложений реального времени, называемого «графом отрисовки кадра», и в первую очередь вопросу оптимизации потребления видеопамяти транзиентными ресурсами используя преимущества этой архитектуры. Этот подход представляет структуру программы как вычислительный граф, что позволяет автоматизировать различные оптимизации, сводя их к алгоритмическим задачам. В частности оптимизация потребления памяти сводится к обобщению широко известной задачи динамической аллокации памяти. В данной работе формулируется необходимое обобщение и приводится полиномиальная схема приближенного решения.

Содержание

1	Введение		
	1.1	Управление ресурсами в графических приложениях реального времени	4
	1.2	Кадровый граф	5
2	ор существующих работ	6	
	2.1	Комплексные решения	6
	2.2	Аллокания ресурсов	8

1. Введение

1.1. Управление ресурсами в графических приложениях реального времени

В процессе вычисления картинки одного кадра любое нетривиальное приложение использует *транзиентные ресурсы* — промежуточные хранилища данных, содержимое которых не требуется после окончания вычисления кадра, либо, требуется лишь в процессе вычисления следующего кадра. Основная отличительная черта рассматриваемого подхода заключается в известности всей информации о транзиентных ресурсах заранее, что позволяет управлять ими более эффективно. Более того, рассматриваемый подход позволяет добиться в определённом смысле оптимальной работы с такими ресурсами, как будет видно дальше. Однако обязательным пререквизитом для эффективной аллокации ресурсов является использование современного графического API, предоставляющего возможность ручного управления видеопамятью. До появления подобных API большая часть приложений использовало один из следующих наивных подходов к управлению ресурсами.

Самый простым подходом является выделение и освобождение транзиентных ресурсов по ходу их нужды при помощи соответствующих вызовов графического API. Этот подход фактически идентичен выделению памяти в различных языках программирования: драйвер операционной системы содержит аллокатор, на который пользователь перекладывает обязанность управления памятью и другими ресурсами GPU, аналогично аллокациям на куче в языке С. Системный аллокатор переиспользует освободившуюся память, тем самым достигая низкого её потребления. Однако такой подход не масштабируется на более сложные приложения. Во-первых известны нижние оценки на качество работы аллокаторов [ССЫЛК НА ОЦЕНКУ ОНЛАЙН DSA], на практике выражающиеся как фрагментация кучи. Во-вторых, как правило этот подход подразумевает использование подсчёта количества ссылок на выделенные ресурсы, что приводит к значительным накладным расходам по всему приложению.

Альтернативным подходом служит отказ от переиспользования памяти. Все транзиентные ресурсы создаются заранее и не удаляются в ходе работы приложения. Очевидно что с повышением сложности приложения такой подход перестаёт быть применимым, что нередко влечёт к попыткам в ручную переиспользовать некоторые выделенные объекты. Это в свою

очередь приводит к чрезвычайно сложному для понимания коду, усложняя работу над самим приложением.

Наконец, наиболее практичным из альтернативных подходом является пулинг ресурсов. Вся программа работает с объектом называемым пулом, отвечающим за выделение и освобождение ресурсов. Пул использует аллокатор драйвера для выделения новых ресурсов, но вместо освобождения ресурсов в драйвер хранит список неиспользуемых ресурсов конкретного типа (в понятие тип как правило входит разрешение для текстур и размер для буфферов соответственно, а также все флаги свойств ресурса). Последующие запросы на выделение ресурсов обслуживаются в первую очередь из списка неиспользуемых, и только исчерпав его выделяются новые посредством драйвера операционной системы. Данный подход был оптимален до появления современных низкоуровневых графических API, однако в настоящее время хорошо заметен его главный недостаток: память не переиспользуется между ресурсами разных типов.

1.2. Кадровый граф

Написать про: * память * архитектурную крутизну ресурсных зависимостей * барьеры * рендерпассы и TBDR * автоматический подбор хорошего для платформы порядка исполнения * многопоточную запись комманд * автоматический асинк * мультиплексирование и прочие "циклы" * историю ресурсов

2. Обзор существующих работ

2.1. Комплексные решения

Frostbite

Первыми идею организации архитектуры рендеринга в приложениях реального времени через вычислительные графы предложили разработчики движка Frostbite в 2017 году[1]. Кадровый граф позволил им сделать ядро модуля рендеринга расширяемым, упростил работу с асинхронным вычислениями общего назначения на GPU, автоматизировал работу со специализированными видами оперативной видеопамяти на игровых консолях, а также сэкономил большое количество обычной видеопамяти. В силу проприетарности движка не известно, насколько широкий класс сценариев использования ресурсов она поддерживает. В качестве схемы аллокации ресурсов же был взят обычный онлайн-аллокатор, располагающий в заранее выделенном крупном участке памяти ресурсы по мере необходимости. Автоматическая расстановка барьеров на 2017 год не поддерживалась.

Halcyon

Далее, в 2019 году, компания EA представила[2] новый экспериментальный движок Halcyon, обобщающий идею кадрового графа до графа рендеринга. Как следует из названия, это обобщение позволяет организовывать в виде графа вычислений не только процесс рендеринга самого кадра, но и рендеринг различных вспомогательных изображений, например кубических карт для некоторых техник глобального освещения, изображений импосторов, или различных иконок в приложении. Более того, граф рендеринга может состоять из нескольких подграфов, запускающихся с разной частотой, например подграф, вычисляющий тени от солнца, может запускаться только при значительном изменении положения солнца на небе. В отличии от Frostbite, граф Halcyon поддерживает автоматическую расстановку барьеров. Также на выступлении отмечается, что изначально граф составлялся явной композицией вершин и подграфов, но в итоге разработчики пришли к дизайну с автоматической композицией вершин на основе глобально видимых имён ресурсов. Про алгоритм аллокации ресурсов и поддержку переживающих границу кадра ресурсов публично доступной информации нет.

Наконец, граф рендеринга Halcyon способен в автоматическом режиме масштабироваться на несколько аппаратных графических ускорителей, и даже на несколько компьютеров. Под-

держка такого функционала весьма сложна и говорит об экспериментальности этой разработки, так как на практике такая масштабируемость редко применима.

Unreal Engine

Начиная с версии 4.22 в Unreal Engine начал переходить на рендеринг через систему "Render Dependency Graph"[3], представляющую собой граф рендеринга. Однако даже в 5й версии движка эта система использует жадную он-лайн стратегию аллокации ресурсов, хоть и поддерживает большое количество важного функционала: автоматизацию асинхронных вычислений на GPU, расстановку барьеров и параллелизацию исполнения графа.

Unity

Разработчики движка Unity, следуя общему направлению индустрии, в 2018 году перевели архитектуру рендеринга на подход вычислительных графов[4]. Однако среди прочих проприетарных движков про граф рендеринга Unity известно, пожалуй, меньше всего. Отметить стоит лишь наличие интеграции между нативным и скриптовым кодом рендеринга, позволяющей сократить время итерации при разработке приложений.

Anvil

Движок Anvil компании Ubisoft с переходом на DirectX12 тоже начал выделять подсистему зависимостей ресурсов, хоть и не называя её графом кадра[5][6]. Согласно выступлениям на GDC, эта система поддерживает многий функционал уже упомянутых: переиспользует память ресурсов, автоматически расставляет барьеры, автоматизирует асинхронные вычисления. Но как и в случае Unity, детали устройства отсутствуют в публичном доступе.

Render Pipeline Shaders

Выпущенная в открытый доступ[7] в декабре 2022 года библиотека Render Pipeline Shaders компании AMD в своём составе имеет комплексное решение для построение кадровых графов[8]. Эта библиотека полностью скрывает от пользователя управление транзиентными ресурсами посредством предметно-ориентированного языка, автоматически переиспользуя ресурсы, расставляя барьеры и клонируя объявленные единожды вершины графа. [ПРОЧИ-ТАТЬ ИСХОДНИКИ И НАПИСАТЬ ЕШО]

Granite

Наконец, стоит упомянуть о существовании многих любительских проектов по написанию обобщённой библиотеки кадровых графов. Большинство из них находятся на стадии зарождения и не заслуживают подробного рассмотрения. Исключеним является проект Granite[9], в рамках которого разработан кадровый граф адаптированный для использования на мобильных устройствах посредством API Vulkan. Кадровый граф Granite автоматически расставляет примитивы синхронизации, группирует ноды в рендер-пассы[10, раздел 8], оптимизирует порядок исполнения вершин с точки зрения минимизации накладных расходов на синхронизацию, а также переиспользует память, хоть и при помощи жадного алгоритма аллокации.

2.2. Аллокация ресурсов

Задача поиска расписания аллокации ресурсов в графе кадра в своей простейшей формулировке является классической сильно NP-сложной[11] задачей динамической аллокации памяти (dynamic storage allocation, DSA[12, с. 226]). У этой задачи существует две интерпретации, он-лайн и офф-лайн. Первая подразумевает обработку разнесённых во времени запросов на аллокацию и деаллокацию ресурсов, иначе говоря, решения об адресах ресурсов в памяти необходимо принимать в порядке времён появления ресурсов. Этот частный случай часто встречается в операционных системах и рантаймах языков программирования. Вторая же интерпретация подразумевает наличие заранее известных времён жизни всех ресурсов. В рамках данной работы нас интересует именно офф-лайн интерпретация, поэтому, в отсутствие уточнения, под задачей о динамической аллокации памяти мы будем подразумевать именно её.

Одним из первых полиномиальных алгоритмов предложенных для решения задачи DSA является алгоритм First-Fit[13], работающий, как было вскоре доказано Кирстедом, с константной ошибкой не более чем в 80 раз[14]. Тремя годами позже Кирстед представил алгоритм с ошибкой не более чем в 6 раз[15]. Эти и другие ранние работы объединяет общий подход сведения DSA к частному случаю с единичным размером всех ресурсов, эквивалентному покраске интервального графа, и последующим применением он-лайн алгоритма покраски. Через несколько лет Йордан Гергов, отказавшись от сведения к интервальным графам, смог понизить верхнюю оценку минимальной возможной ошибки до 5[16], а в последствии и до 3[17]. Наконец, наилучший на данный момент результат был получен исследователями

из AT&T Labs совместно с коллегой из Ecole Polytechnique[18]: полиномиальный алгоритм, для любого заранее выбранного ε дающий $(2+\varepsilon)$ -приблизительное решение DSA. Более того, для некоторых частных случаев авторы предоставляют приближённую схему полиномиального времени (то есть $(1+\varepsilon)$ -приближение). Из них в рамках графа кадра особо интересна схема для случая ресурсов, размер которых ограничен сверху константой h_{max} . Однако практичность представленных алгоритмов в рамках приложений реального времени является открытым вопросом в силу их высокой сложности (ТОDO: оценить асимптотику по мастер-теореме).

Похожая задача возникает в области оперирования морских контейнерных терминалов. С ростом сложности и нагруженности глобальных транспортных цепочек, прикладные задачи оперирования верфей стали слишком сложны для интуитивного их решения. В связи с этим за последние несколько десятилетий было сформулировано и в той или иной степени решено множество вариаций задачи об аллокации верфи, покрывающих широкий спектр прикладных задач. Так как расписания прибытия кораблей обычно известно портам заранее, офф-лайн задача динамической аллокации памяти является частным случаем одной из формулировок этой задачи, а именно вариации классифицируемой в обзорной статье Бирвирта и Мизла[19] как cont|dyn|fix|max(res). Именно из-за этого задача об аллокации верфи представляет интерес в рамках данной работы.

Одним из первых интересующую нас формулировку задачи об аллокации верфи рассмотрел в своей статье Эндрю Лим[20]. Ресурсы, имеющие фиксированные и известные размер и времена аллокации и деаллокации, могут быть рассмотрены как корабли с соответствующей длинной, временем прибытия и временем отплытия, а тип используемой видеопамяти как секция верфи. Задача нахождения минимальной длинны всех секций верфи и точек прибытия всех кораблей аналогична нахождению минимального необходимого объёма памяти и локаций всех ресурсов в этой памяти. Однако, в отличии от рассматриваемой Лимом задачи, ресурсы не накладывают требований на отступ между друг другом и началом или концом верфи, зато требуют определённого выравнивания их начала в памяти. Впрочем, последние условие достаточно легко сводится к первому.

Однако в данной работе рассматривается более общая формулировка задачи об аллокации

ресурсов, насколько известно автору, не рассматривавшаяся ранее в литератур	e.

Список литературы

- 1. O'Donnell Y. FrameGraph: Extensible Rendering Architecture in Frostbite. 2017. URL: https://www.gdcvault.com/play/1024612; Game Developers Conference.
- 2. Wihlidal G. Halcyon: Rapid innovation using modern graphics. 2019. URL: https://www.youtube.com/watch?v=da_6dsWz8yg; Reboot Develop.
- 3. Games E. Unreal Engine rebder dependency graph. URL: https://docs.unrealengine. com/5.0/en-US/render-dependency-graph-in-unreal-engine/.
- 4. *Tatarchuk N.*, *Aaltonen S.*, *Cooper T.* Unity Rendering Architecture. 2021. URL: https://www.youtube.com/watch?v=6LzcXPIWUbc; SIGGRAPH 2021 REAC.
- 5. *Gruen H.* DirectXTM 12 Case Studies. 2017. URL: https://www.gdcvault.com/play/1024343; Game Developers Conference.
- 6. Rodrigues T. Moving to DirectX 12: Lessons Learned. 2017. URL: https://www.gdcvault.com/play/1024656; Game Developers Conference.
- 7. Advanced Micro Devices I. Исходный код Render Pipeline Shaders. URL: https://github.com/GPUOpen-LibrariesAndSDKs/RenderPipelineShaders.
- 8. Advanced Micro Devices I. Анонс публикации Render Pipeline Shaders. URL: https://gpuopen.com/learn/rps_1_0.
- 9. Arntzen H.-K. Render graphs and Vulkan a deep dive. 2017. URL: https://themaister.net/blog/2017/08/15/render-graphs-and-vulkan-a-deep-dive/.
- 10. Inc. T. K. G. Vulkan API Specification. URL: https://registry.khronos.org/vulkan/specs/1.3-extensions/html/vkspec.html.
- 11. Stockmeyer I. J. 1976. личная переписка.
- 12. *Garey M. R.*, *Johnson D. S.* Computers and Intractability; A Guide to the Theory of NP-Completeness. USA: W. H. Freeman & Co., 1990. ISBN 0716710455.
- 13. Chrobak M., Ślusarek M. On some packing problem related to dynamic storage allocation // RAIRO Theoretical Informatics and Applications. 1988. Vol. 22, no. 4. P. 487—499. ISSN 0988-3754, 1290-385X. DOI: 10.1051/ita/1988220404871. URL: http://www.rairo-ita.org/10.1051/ita/1988220404871 (visited on 10/23/2022).
- 14. *Kierstead H. A.* The Linearity of First-Fit Coloring of Interval Graphs // SIAM Journal on Discrete Mathematics. 1988. Nov. Vol. 1, no. 4. P. 526–530. ISSN 0895-4801,

- 1095-7146. DOI: 10.1137/0401048. URL: http://epubs.siam.org/doi/10.1137/0401048 (visited on 10/23/2022).
- 15. *Kierstead H. A.* A polynomial time approximation algorithm for dynamic storage allocation // Discrete Mathematics. 1991. T. 88, № 2. C. 231—237. Publisher: Elsevier.
- 16. *Gergov J.* Approximation algorithms for dynamic storage allocation // European Symposium on Algorithms. Springer, 1996. C. 52—61.
- 17. *Gergov J.* Algorithms for compile-time memory optimization // Proceedings of the tenth annual ACM-SIAM symposium on Discrete algorithms. 1999. C. 907—908.
- 18. OPT versus LOAD in dynamic storage allocation / A. L. Buchsbaum [и др.] // Proceedings of the thirty-fifth annual ACM symposium on Theory of computing. 2003. С. 556—564.
- 19. Bierwirth C., Meisel F. A survey of berth allocation and quay crane scheduling problems in container terminals // European Journal of Operational Research. 2010. T. 202, № 3. C. 615—627. ISSN 0377-2217. DOI: https://doi.org/10.1016/j.ejor. 2009.05.031. URL: https://www.sciencedirect.com/science/article/pii/S0377221709003579.
- Lim A. The berth planning problem // Operations Research Letters. 1998. T. 22, № 2. C. 105—110. ISSN 0167-6377. DOI: https://doi.org/10.1016/S0167-6377(98)00010 8. URL: https://www.sciencedirect.com/science/article/pii/S0167637798000108.