

Федеральное государственное автономное образовательное учреждение  
высшего образования

«Московский физико-технический институт (государственный университет)»

Физтех-школа прикладной математики и информатики

Центр обучения проектированию и разработке игр

**Направление подготовки:** 09.04.01 Информатика и вычислительная техника

**Направленность (профиль) подготовки:** Анализ данных и разработка информационных систем

# **Оптимизация потребления видеопамати при помощи вычислительного графа в приложениях реального времени**

(магистерская диссертация)

**Студент:**

Санду Роман Александрович

---

*(подпись студента)*

**Научный руководитель:**

Щербаков Александр Станиславович

---

*(подпись научного руководителя)*

Москва 2023

### **Аннотация**

Данная работа посвящена подходу к построению архитектуры приложений реального времени, называемому «графом отрисовки кадра», в частности вопросу оптимизации потребления видеопамати транзистными ресурсами используя преимущества этой архитектуры. Структура программы представляется как вычислительный граф, что позволяет автоматизировать различные аспекты разработки современных приложений реального времени, сводя их к алгоритмическим задачам. В рамках работы оптимизация потребления памяти сводится к обобщению широко известной задачи динамической аллокации памяти, проводится эффективный алгоритм решения этой задачи, а также освещаются различные инженерные аспекты имплементации системы графов отрисовки кадра.

# Содержание

<b>1</b>	<b>Введение</b>	<b>4</b>
1.1	Аспекты разработки графических приложений реального времени в старых и новых API . . . . .	5
1.1.1	Управление памятью транзистентных ресурсов GPU . . . . .	5
1.1.2	Отправка команд GPU . . . . .	6
1.1.3	Управление кешами GPU . . . . .	7
1.2	Кадровый граф . . . . .	7
<b>2</b>	<b>Обзор существующих работ</b>	<b>8</b>
2.1	Комплексные решения . . . . .	8
2.2	Аллокация ресурсов . . . . .	10

# 1. Введение

Около 10 лет назад история развития компьютерной графики реального времени потерпела кардинальный поворот с выходом графических API нового поколения, DirectX12, Vulkan и Metal, в 2014, 2016 и 2014 годах соответственно. Их предшественники, OpenGL и DirectX ранних версий, основывались на идее так называемого «толстого» драйвера. Дизайн этих API старался максимально скрыть принципы работы видеокарт, предоставляя пользователям простой, но достаточно ограниченный инструмент для разработки графических приложений реального времени. По мере развития индустрии компьютерной графики, разработчики приложений всё чаще сталкивались с ограничениями старых API, а простота дизайна всё больше жертвовалась в пользу поддержки новых возможностей графических ускорителей. Обусловлено это возрастающими требованиями к приложениям со стороны клиентов.

В индустриях игр, кино, виртуальных тренировочных симуляторов, а также промышленной визуализации, очень важно качество и реализм картинки. За годы академических исследований компьютерной графики было предложено большое количество техник и алгоритмов визуализации самых различных сцен, а развитие потребительской и промышленной техники привело к распространению широкого спектра устройств для запуска приложений. Так, не редка ситуация в которой одно и то же приложение должно масштабироваться от профессиональных персональных компьютеров с мощнейшими процессорами, видеокартами и мониторами в разрешении 8K, и до потребительских HMD-устройств, и даже телефонов и портативных консолей. От разработчиков приложений ожидается масштабируемость на этот широкий спектр устройств, с учётом всей их специфики, при этом не отказываясь от использования современных алгоритмов и техник визуализации сцен.

Главной целью дизайна графических API нового поколения было позволить разработчикам добиться этой цели, в следствии чего произошёл отказ от «толстых» драйверов в пользу раскрытия всё большего числа деталей работы графических ускорителей. В следующем разделе более детально освещены различные аспекты этого перехода, а также проблемы, возникающие при разработке приложений с использованием новых графических API.

## 1.1. Аспекты разработки графических приложений реального времени в старых и новых API

### 1.1.1. Управление памятью транзитных ресурсов GPU

В процессе вычисления картинки одного кадра любое нетривиальное приложение использует *транзитные ресурсы* – промежуточные хранилища данных, содержимое которых не требуется после окончания вычисления кадра, либо, требуется лишь в процессе вычисления следующего кадра. Как правило, подобные ресурсы являются картинками с разрешением кратным разрешению монитора пользователя. Из этого следует, что при переходе от 1080p мониторов к 4K мониторам потребление памяти транзитными ресурсами возрастает в 4 раза, что обуславливает нужду в эффективном её переиспользовании. Старые графические API полностью скрывали управление памятью GPU от пользователя, предоставляя лишь функции создания и удаления конкретных ресурсов. За годы существования этой абстракции образовалось 3 основных подхода к эффективному управлению памятью транзитных ресурсов.

Самый простым подходом является выделение и освобождение транзитных ресурсов по ходу их нужды при помощи соответствующих вызовов графического API. Этот подход фактически идентичен выделению памяти в различных языках программирования: драйвер операционной системы содержит аллокатор, на который пользователь перекладывает обязанность управления памятью и другими ресурсами GPU, аналогично аллокациям на куче в языке C. Системный аллокатор переиспользует освободившуюся память, тем самым достигая низкого её потребления. Однако, такой подход не масштабируется на более сложные приложения. Во-первых известны нижние оценки на качество работы аллокаторов реального времени [1.ссылка на оценку онлайн DSA](#), на практике выражающиеся как фрагментация кучи. Во-вторых, как правило и создание и освобождение ресурсов является весьма дорогой операцией в следствии деталей реализации драйверов. [2.мб объяснить почему?](#)

Альтернативным подходом служит отказ от переиспользования памяти. Все транзитные ресурсы создаются заранее и не удаляются в ходе работы приложения. Очевидно, что с повышением сложности приложения такой подход перестаёт быть применимым, что иногда влечёт к попыткам вручную переиспользовать некоторые выделенные объекты. Это, в свою

очередь, приводит к чрезвычайно сложному для понимания коду, усложняя работу над самим приложением.

Наконец, наиболее практичным подходом является пуллинг ресурсов. Вся программа работает с объектом называемым пулом, отвечающим за выделение и освобождение ресурсов. Пул использует аллокатор драйвера для выделения новых ресурсов, но вместо освобождения ресурсов в драйвер хранит список неиспользуемых ресурсов конкретного типа (в понятие тип как правило входит разрешение для текстур и размер для буфферов соответственно, а также все флаги свойств ресурса). Последующие запросы на выделение ресурсов обслуживаются в первую очередь из списка неиспользуемых, и только исчерпав его выделяются новые посредством драйвера операционной системы. Данный подход был оптимален до появления современных низкоуровневых графических API, однако в настоящее время хорошо заметен его главный недостаток: память не переиспользуется между ресурсами разных типов.

В современных же графических API предоставляется прямой доступ к памяти GPU. Приложение может выделять *кучи* в видеопамяти, последовательности страниц виртуальной видеопамяти, и затем создавать ресурсы на конкретных адресах на куче. Стоит отметить, что пересечение используемых разными ресурсами регионов кучи не запрещается, хоть поведение при одновременном использовании таких ресурсов не определено. Фактически, это нововведение перекладывает ответственность по написанию аллокатора ресурсов с разработчиков драйвера на разработчиков приложения. С одной стороны, это сильно усложняет разработку простых приложений, в следствии чего компания AMD открыла исходный код аллокатора из своих драйверов [3.ссылка](#). С другой стороны, это даёт возможность разработчикам более эффективно распоряжаться видеопамятью в различных частях приложения, в частности, позволяя построить в некотором смысле оптимальное расписание аллокации транзистных ресурсов.

### 1.1.2. Отправка команд GPU

4.Написать про *async compute* и проблемы с многопоточностью

### 1.1.3. Управление кешами GPU

5.Написать про барьеры

## 1.2. Кадровый граф

6.Написать про:

- 7.память
- 8.архитектурную крутизну ресурсных зависимостей
- 9.барьеры
- 10.рендерпассы и TBDR
- 11.автоматический подбор хорошего для платформы порядка исполнения
- 12.многопоточную запись команд
- 13.автоматический асинк
- 14.мультиплексирование и прочие "циклы"
- 15.историю ресурсов

## 2. Обзор существующих работ

### 2.1. Комплексные решения

#### Frostbite

Первыми идею организации архитектуры рендеринга в приложениях реального времени через вычислительные графы предложили разработчики движка Frostbite в 2017 году[1]. *Кадровый граф* позволил им сделать ядро модуля рендеринга расширяемым, упростил работу с асинхронным вычислениями общего назначения на GPU, автоматизировал работу со специализированными видами оперативной видеопамяти на игровых консолях, а также сэкономил большое количество обычной видеопамяти. В силу проприетарности движка не известно, насколько широкий класс сценариев использования ресурсов она поддерживает. В качестве схемы аллокации ресурсов же был взят обычный онлайн-аллокатор, располагающий в заранее выделенном крупном участке памяти ресурсы по мере необходимости. Автоматическая расстановка барьеров на 2017 год не поддерживалась.

#### Halcyon

Далее, в 2019 году, компания EA представила[2] новый экспериментальный движок Halcyon, обобщающий идею кадрового графа до *графа рендеринга*. Как следует из названия, это обобщение позволяет организовывать в виде графа вычислений не только процесс рендеринга самого кадра, но и рендеринг различных вспомогательных изображений, например кубических карт для некоторых техник глобального освещения, изображений импосторов, или различных иконок в приложении. Более того, граф рендеринга может состоять из нескольких подграфов, запускающихся с разной частотой, например подграф, вычисляющий тени от солнца, может запускаться только при значительном изменении положения солнца на небе. В отличие от Frostbite, граф Halcyon поддерживает автоматическую расстановку барьеров. Также на выступлении отмечается, что изначально граф составлялся явной композицией вершин и подграфов, но в итоге разработчики пришли к дизайну с автоматической композицией вершин на основе глобально видимых имён ресурсов. Про алгоритм аллокации ресурсов и поддержку переживающих границу кадра ресурсов публично доступной информации нет.

Наконец, граф рендеринга Halcyon способен в автоматическом режиме масштабироваться на несколько аппаратных графических ускорителей, и даже на несколько компьютеров. Под-



держка такого функционала весьма сложна и говорит об экспериментальности этой разработки, так как на практике такая масштабируемость редко применима.

## **Unreal Engine**

Начиная с версии 4.22 в Unreal Engine начал переходить на рендеринг через систему "Render Dependency Graph"[3], представляющую собой граф рендеринга. Однако даже в 5й версии движка эта система использует жадную он-лайн стратегию аллокации ресурсов, хоть и поддерживает большое количество важного функционала: автоматизацию асинхронных вычислений на GPU, расстановку барьеров и параллелизацию исполнения графа.

## **Unity**

Разработчики движка Unity, следуя общему направлению индустрии, в 2018 году перевели архитектуру рендеринга на подход вычислительных графов[4]. Однако среди прочих проприетарных движков про граф рендеринга Unity известно, пожалуй, меньше всего. Отметить стоит лишь наличие интеграции между нативным и скриптовым кодом рендеринга, позволяющей сократить время итерации при разработке приложений.

## **Anvil**

Движок Anvil компании Ubisoft с переходом на DirectX12 тоже начал выделять подсистему зависимостей ресурсов, хоть и не называя её графом кадра[5][6]. Согласно выступлениям на GDC, эта система поддерживает многих функционал уже упомянутых: переиспользует память ресурсов, автоматически расставляет барьеры, автоматизирует асинхронные вычисления. Но как и в случае Unity, детали устройства отсутствуют в публичном доступе.

## **Render Pipeline Shaders**

Выпущенная в открытый доступ[7] в декабре 2022 года библиотека Render Pipeline Shaders компании AMD в своём составе имеет комплексное решение для построения кадровых графов[8]. Эта библиотека полностью скрывает от пользователя управление транзитными ресурсами посредством предметно-ориентированного языка, автоматически переиспользуя ресурсы, расставляя барьеры и клонируя объявленные единожды вершины графа. [ПРОЧИТАТЬ ИСХОДНИКИ И НАПИСАТЬ ЕШО]

## Granite

Наконец, стоит упомянуть о существовании многих любительских проектов по написанию обобщённой библиотеки кадровых графов. Большинство из них находятся на стадии зарождения и не заслуживают подробного рассмотрения. Исключением является проект Granite[9], в рамках которого разработан кадровый граф адаптированный для использования на мобильных устройствах посредством API Vulkan. Кадровый граф Granite автоматически расставляет примитивы синхронизации, группирует ноды в рендер-пассы[10, раздел 8], оптимизирует порядок исполнения вершин с точки зрения минимизации накладных расходов на синхронизацию, а также переиспользует память, хоть и при помощи жадного алгоритма аллокации.

## 2.2. Аллокация ресурсов

Задача поиска расписания аллокации ресурсов в графе кадра в своей простейшей формулировке является классической сильно NP-сложной[11] задачей *динамической аллокации памяти* (dynamic storage allocation, DSA[12, с. 226]). У этой задачи существует две интерпретации, он-лайн и офф-лайн. Первая подразумевает обработку разнесённых во времени запросов на аллокацию и деаллокацию ресурсов, иначе говоря, решения об адресах ресурсов в памяти необходимо принимать в порядке времён появления ресурсов. Этот частный случай часто встречается в операционных системах и рантаймах языков программирования. Вторая же интерпретация подразумевает наличие заранее известных времён жизни всех ресурсов. В рамках данной работы нас интересует именно офф-лайн интерпретация, поэтому, в отсутствие уточнения, под задачей о динамической аллокации памяти мы будем подразумевать именно её.

Одним из первых полиномиальных алгоритмов предложенных для решения задачи DSA является алгоритм First-Fit[13], работающий, как было вскоре доказано Кирстедом, с константной ошибкой не более чем в 80 раз[14]. Три годами позже Кирстед представил алгоритм с ошибкой не более чем в 6 раз[15]. Эти и другие ранние работы объединяет общий подход сведения DSA к частному случаю с единичным размером всех ресурсов, эквивалентному покраске интервального графа, и последующим применением он-лайн алгоритма покраски. Через несколько лет Йордан Гергов, отказавшись от сведения к интервальным графам, смог понизить верхнюю оценку минимальной возможной ошибки до 5[16], а в последствии и до 3[17]. Наконец, наилучший на данный момент результат был получен исследователями

из AT&T Labs совместно с коллегой из Ecole Polytechnique[18]: полиномиальный алгоритм, для любого заранее выбранного  $\varepsilon$  дающий  $(2 + \varepsilon)$ -приближительное решение DSA. Более того, для некоторых частных случаев авторы предоставляют приближённую схему полиномиального времени (то есть  $(1 + \varepsilon)$ -приближение). Из них в рамках графа кадра особо интересна схема для случая ресурсов, размер которых ограничен сверху константой  $h_{max}$ . Однако практичность представленных алгоритмов в рамках приложений реального времени является открытым вопросом в силу их высокой сложности (TODO: оценить асимптотику по мастер-теореме).

Похожая задача возникает в области оперирования морских контейнерных терминалов. С ростом сложности и нагруженности глобальных транспортных цепочек, прикладные задачи оперирования верфёй стали слишком сложны для интуитивного их решения. В связи с этим за последние несколько десятилетий было сформулировано и в той или иной степени решено множество вариаций *задачи об аллокации верфи*, покрывающих широкий спектр прикладных задач. Так как расписания прибытия кораблей обычно известно портам заранее, офф-лайн задача динамической аллокации памяти является частным случаем одной из формулировок этой задачи, а именно вариации классифицируемой в обзорной статье Бирвирта и Мизла[19] как  $cont|dyn|fix|max(res)$ . Именно из-за этого задача об аллокации верфи представляет интерес в рамках данной работы.

Одним из первых интересующую нас формулировку задачи об аллокации верфи рассмотрел в своей статье Эндрю Лим[20]. Ресурсы, имеющие фиксированные и известные размер и времена аллокации и деаллокации, могут быть рассмотрены как корабли с соответствующей длиной, временем прибытия и временем отплытия, а тип используемой видеопамати как секция верфи. Задача нахождения минимальной длины всех секций верфи и точек прибытия всех кораблей аналогична нахождению минимального необходимого объёма памяти и локаций всех ресурсов в этой памяти. Однако, в отличие от рассматриваемой Лимом задачи, ресурсы не накладывают требований на отступ между друг другом и началом или концом верфи, зато требуют определённого выравнивания их начала в памяти. Впрочем, последнее условие достаточно легко сводится к первому.

Однако в данной работе рассматривается более общая формулировка задачи об аллокации

ресурсов, насколько известно автору, не рассматривавшаяся ранее в литературе.

## Список литературы

1. *O'Donnell Y.* FrameGraph: Extensible Rendering Architecture in Frostbite. — 2017. — URL: <https://www.gdcvault.com/play/1024612> ; Game Developers Conference.
2. *Wihlidal G.* Halcyon: Rapid innovation using modern graphics. — 2019. — URL: [https://www.youtube.com/watch?v=da\\_6dsWz8yg](https://www.youtube.com/watch?v=da_6dsWz8yg) ; Reboot Develop.
3. *Games E.* Unreal Engine render dependency graph. — URL: <https://docs.unrealengine.com/5.0/en-US/render-dependency-graph-in-unreal-engine/>.
4. *Tatarchuk N., Aaltonen S., Cooper T.* Unity Rendering Architecture. — 2021. — URL: <https://www.youtube.com/watch?v=6LzcXPIWUbc> ; SIGGRAPH 2021 REAC.
5. *Gruen H.* DirectX™ 12 Case Studies. — 2017. — URL: <https://www.gdcvault.com/play/1024343> ; Game Developers Conference.
6. *Rodrigues T.* Moving to DirectX 12: Lessons Learned. — 2017. — URL: <https://www.gdcvault.com/play/1024656> ; Game Developers Conference.
7. *Advanced Micro Devices I.* Исходный код Render Pipeline Shaders. — URL: <https://github.com/GPUOpen-LibrariesAndSDKs/RenderPipelineShaders>.
8. *Advanced Micro Devices I.* Анонс публикации Render Pipeline Shaders. — URL: [https://gpuopen.com/learn/rps\\_1\\_0](https://gpuopen.com/learn/rps_1_0).
9. *Arntzen H.-K.* Render graphs and Vulkan — a deep dive. — 2017. — URL: <https://themaister.net/blog/2017/08/15/render-graphs-and-vulkan-a-deep-dive/>.
10. *Inc. T. K. G.* Vulkan API Specification. — URL: <https://registry.khronos.org/vulkan/specs/1.3-extensions/html/vkspec.html>.
11. *Stockmeyer I. J.* — 1976. — личная переписка.
12. *Garey M. R., Johnson D. S.* Computers and Intractability; A Guide to the Theory of NP-Completeness. — USA : W. H. Freeman & Co., 1990. — ISBN 0716710455.
13. *Chrobak M., Ślusarek M.* On some packing problem related to dynamic storage allocation // RAIRO - Theoretical Informatics and Applications. — 1988. — Vol. 22, no. 4. — P. 487–499. — ISSN 0988-3754, 1290-385X. — DOI: [10.1051/ita/1988220404871](https://doi.org/10.1051/ita/1988220404871). — URL: <http://www.rairo-ita.org/10.1051/ita/1988220404871> (visited on 10/23/2022).
14. *Kierstead H. A.* The Linearity of First-Fit Coloring of Interval Graphs // SIAM Journal on Discrete Mathematics. — 1988. — Nov. — Vol. 1, no. 4. — P. 526–530. — ISSN 0895-4801,

- 1095-7146. — DOI: [10.1137/0401048](https://doi.org/10.1137/0401048). — URL: <http://epubs.siam.org/doi/10.1137/0401048> (visited on 10/23/2022).
15. *Kierstead H. A.* A polynomial time approximation algorithm for dynamic storage allocation // Discrete Mathematics. — 1991. — T. 88, № 2. — C. 231—237. — Publisher: Elsevier.
  16. *Gergov J.* Approximation algorithms for dynamic storage allocation // European Symposium on Algorithms. — Springer, 1996. — C. 52—61.
  17. *Gergov J.* Algorithms for compile-time memory optimization // Proceedings of the tenth annual ACM-SIAM symposium on Discrete algorithms. — 1999. — C. 907—908.
  18. OPT versus LOAD in dynamic storage allocation / A. L. Buchsbaum [и др.] // Proceedings of the thirty-fifth annual ACM symposium on Theory of computing. — 2003. — C. 556—564.
  19. *Bierwirth C., Meisel F.* A survey of berth allocation and quay crane scheduling problems in container terminals // European Journal of Operational Research. — 2010. — T. 202, № 3. — C. 615—627. — ISSN 0377-2217. — DOI: <https://doi.org/10.1016/j.ejor.2009.05.031>. — URL: <https://www.sciencedirect.com/science/article/pii/S0377221709003579>.
  20. *Lim A.* The berth planning problem // Operations Research Letters. — 1998. — T. 22, № 2. — C. 105—110. — ISSN 0167-6377. — DOI: [https://doi.org/10.1016/S0167-6377\(98\)00010-8](https://doi.org/10.1016/S0167-6377(98)00010-8). — URL: <https://www.sciencedirect.com/science/article/pii/S0167637798000108>.